

REPORT • JUNIO 2026

Informe Final de Consultoria

Informe Final de Consultoría

Plataforma Analítica de Mortalidad End-to-End: Análisis Pre-COVID y Post-COVID en Guatemala y Centroamérica

Resumen Ejecutivo

El presente informe documenta los resultados de la consultoría contratada por el Programa de las Naciones Unidas para el Desarrollo (PNUD), en acompañamiento al Ministerio de Salud Pública y Asistencia Social (MSPAS) de Guatemala, para el diseño, implementación y demostración de una Plataforma Analítica de Mortalidad End-to-End. El objetivo del encargo fue comprender cómo cambiaron los patrones de mortalidad en Guatemala y la región centroamericana entre el período pre-COVID (2015–2019) y el período post-COVID (2020 en adelante), con el fin de orientar decisiones de política pública y asignación de recursos.

La solución desarrollada consistió en una arquitectura híbrida (nube y local) que integró fuentes heterogéneas de datos de mortalidad —INE Guatemala, MSPAS, IHME GBD 2023, WHO Mortality Database, INEC Panamá, entre otras— mediante pipelines de ingesta implementados en Databricks sobre Azure. Los datos fueron gobernados bajo una arquitectura por capas (Sandbox, Stage, Fact-Dimensions) hacia un repositorio analítico tipo Data Warehouse interoperable entre un DW en la nube (Databricks Delta Lake) y un DW local (Greenplum). Sobre esta base se aplicaron modelos de Machine Learning, se construyeron dashboards analíticos en Power BI y Apache Superset, y se derivaron hallazgos basados en evidencia.

Los principales hallazgos del análisis revelan que Guatemala concentra la mayor carga absoluta de mortalidad en Centroamérica (779,300 defunciones, 34% del total regional), con un incremento de 56,558 muertes adicionales entre los períodos pre y post-COVID (+15.65%). Las infecciones respiratorias y tuberculosis, y no la categoría específica de COVID-19, fueron las causas que registraron el mayor pico de mortalidad durante la pandemia, sugiriendo un patrón de subregistro o clasificación imprecisa. Las enfermedades cardiovasculares y la diabetes/enfermedades renales constituyen las principales causas de muerte estructurales en Guatemala, con una persistencia del exceso de mortalidad que no ha retornado a los niveles pre-pandemia incluso en 2024. El departamento de Guatemala concentra la mayor mortalidad absoluta, mientras que departamentos del corredor seco y con alta población indígena muestran patrones de desigualdad en salud que requieren intervenciones focalizadas.

Se recomienda fortalecer el sistema de registro de estadísticas vitales, implementar programas de prevención de enfermedades crónicas no transmisibles, priorizar intervenciones en los departamentos con mayor carga de mortalidad prevenible, mejorar la calidad de la codificación CIE-10, y establecer un sistema de monitoreo continuo de exceso de mortalidad como indicador centinela.

Metodología del Proyecto

Marco de Trabajo: Ágil Scrum

El proyecto fue ejecutado bajo el marco de trabajo **Ágil Scrum**, adaptado al contexto de una consultoría de ingeniería de datos con entregables acumulativos. Esta metodología fue seleccionada por su capacidad para gestionar proyectos de alta incertidumbre técnica, permitiendo la inspección y adaptación continua de los entregables a medida que se descubrían las características y limitaciones de las fuentes de datos.

Estructura del Proyecto

El trabajo se organizó en **tres (3) Sprints** de aproximadamente cuatro semanas cada uno, correspondientes a las tres fases acumulativas definidas en los Términos de Referencia del encargo:

Sprint	Duración	Foco Principal	Incremento Demostrable
Sprint 1	4 semanas	Identificación, estructuración, limpieza e ingesta de datos	Datos crudos consolidados en Sandbox con diccionario de datos y plan de anonimización
Sprint 2	4 semanas	Transformación, arquitectura por capas y almacenamiento (DW)	Flujo Sandbox → Stage → Data Warehouse cargado en nube y local interoperables
Sprint 3	4 semanas	Machine Learning, visualización analítica e interoperabilidad BI	Modelos de ML, dashboards en Power BI y Apache Superset, informe final

Roles del Equipo

Rol Scrum	Responsable	Funciones Clave
Product Owner	Representante del PNUD/MSPAS (simulado)	Definir y priorizar el Product Backlog, validar criterios de aceptación
Scrum Master	Integrante del equipo rotativo	Facilitar ceremonias, remover impedimentos, asegurar adherence al marco
Development Team	3 ingenieros de datos	Diseñar, implementar, probar y documentar todos los componentes técnicos

Artefactos

- **Product Backlog:** Lista priorizada de requerimientos funcionales y no funcionales derivados de los Términos de Referencia, incluyendo fuentes de datos, criterios de calidad, requisitos de interoperabilidad y cumplimiento normativo (EU Data Act).
- **Sprint Backlog:** Subconjunto del Product Backlog seleccionado para cada Sprint, desglosado en tareas atómicas con estimaciones de esfuerzo y definiciones de terminado (DoD).
- **Incremento:** Entregable funcional al final de cada Sprint. Por la naturaleza acumulativa del proyecto, cada incremento debía demostrar el flujo end-to-end completo desde la fuente de datos hasta el entregable de la fase correspondiente.

Ceremonias

Ceremonia	Frecuencia	Duración	Propósito
Sprint Planning	Inicio de cada Sprint	4 horas	Seleccionar y desglosar ítems del Product Backlog para el Sprint
Daily Scrum	Diario	15 minutos	Sincronización del equipo, identificación de bloqueos, ajuste del plan diario
Sprint Review	Final de cada Sprint	2 horas	Demostración del incremento funcionando end-to-end, recolección de retroalimentación

Sprint Retrospective	Final de cada Sprint	1.5 horas	Reflexión sobre el proceso, identificación de mejoras para el siguiente Sprint
----------------------	----------------------	-----------	--

Herramientas de Soporte

- **Control de versiones:** GitHub con branching strategy basada en features. Se utilizó `git blame` y `git diff` para trazabilidad de contribuciones individuales.
- **Documentación:** MkDocs con GitHub Actions para despliegue continuo de la documentación técnica.
- **Gestión de tareas:** Tablero Kanban digital con columnas (To Do, In Progress, Review, Done) para seguimiento visual del flujo de trabajo.
- **Comunicación:** Canales sincrónicos para Daily Scrum y comunicación asíncrona para coordinación técnica.

Planificación Temporal

El proyecto abarcó un período total de **cuatro (4) meses calendario**, distribuidos de la siguiente manera:

- **Mes 1:** Sprint 1 — Ingesta y fundamentos de datos
- **Mes 2:** Sprint 2 — Transformación y Data Warehouse
- **Mes 3:** Sprint 3 — Machine Learning y Visualización
- **Mes 4:** Cierre — Consolidación de entregables, informe final, defensa oral

Arquitectura del Sistema

Descripción General

Para dar una solución a los requerimientos del proyecto, se ha optado por tomar una arquitectura híbrida, que pueda interoperar infraestructura on-premise y en la nube, utilizando tecnologías como Databricks, Azure, Power BI, Greenplum, Apache Superset entre otras. Esta arquitectura permite aprovechar las ventajas de ambas infraestructuras, como la escalabilidad y flexibilidad de la nube, así como la seguridad y control que ofrece la infraestructura on-premise.

De igual forma, esta arquitectura fue iterativa, por lo que se fue ajustando y mejorando a medida que se avanzaba en el desarrollo del proyecto, permitiendo así adaptarse a los cambios y nuevas necesidades que pudieran surgir durante el proceso.




Figure 1: Diagrama de Arquitectura de Solución

El desarrollo de la parte de extracción y almacenamiento de datos utilizó Databricks como herramienta principal, operado sobre Azure como plataforma de nube. Para la extracción se utilizaron fuentes heterogéneas: SharePoint, Google Drive, AWS S3, AWS RDS y un servidor web local con Nginx, buscando una solución flexible y adaptable a diferentes fuentes de datos.

El Sandbox, gestionado por Databricks, sirvió para manipular datos que se redirigirían al Data Warehouse tanto local como en la nube. Por su parte, el Stage fue el lugar donde se procesaron y transformaron los datos para luego ser cargados al Data Warehouse, que conforme a los requerimientos, se gestionó de manera interoperable e híbrida.

Para suplir la necesidad del Data Warehouse local, se optó por utilizar Greenplum, un excelente sistema de gestión de bases de datos relacional orientado a la analítica y el procesamiento de grandes volúmenes de datos, de tipo MPP (Massively Parallel Processing).

Para la visualización de los datos, se utilizaron Power BI y Apache Superset, herramientas que permiten crear dashboards interactivos y se integran tanto con el Data Warehouse en la nube como con el local.

Finalmente, para almacenar los artefactos de Machine Learning, se utilizó un bucket de S3 en AWS como repositorio centralizado.

Diagrama de Despliegue




Figure 2: Diagrama de Despliegue

Como se puede observar en el diagrama de despliegue, el sistema está compuesto por varios componentes que interactúan entre sí. Las fuentes de datos heterogéneas se comunican con Databricks a través de diferentes protocolos. Databricks implementa una arquitectura distribuida con dos componentes principales: el driver (coordinación de tareas) y los workers (ejecución de procesamiento). Databricks se encuentra alojado en Azure, aprovechando servicios como Blob Storage.

El cluster de Databricks utiliza secrets para gestionar de manera segura las credenciales y configuraciones necesarias para acceder a las diferentes fuentes de datos y servicios en la nube.

En la esquina inferior derecha del diagrama se observa el Data Warehouse local gestionado por Greenplum. La comunicación entre Databricks y el Data Warehouse local se realiza a través de una conexión segura mediante la API de Databricks. Las herramientas de visualización incluyen Power BI (versión web, conectado a Databricks) y Apache Superset (montado localmente, trabajando con el DW local).

Modelado de Datos

Sandbox

Se ha modelado el Sandbox como un esquema de base de datos que contiene tablas para almacenar la información en crudo sin ser procesada, representando la capa bronce de la arquitectura medallón.



Figure 3: Diagrama de Sandbox

Stage

Se ha modelado el Stage como un esquema que contiene tablas para almacenar la información procesada y transformada, representando la capa plata de la arquitectura medallón.



Figure 4: Diagrama de Stage

Fact-Dimensions

Las tablas Fact-Dimensions representan las dimensiones y hechos del modelo dimensional, organizando la información de manera estructurada para facilitar el análisis. Estas tablas representan la capa oro de la arquitectura medallón.




Figure 5: Diagrama de Fact-Dimensions

Cubos Dimensionales

Cada cubo fue modelado de manera individual con sus respectivas dimensiones y hechos para facilitar la comprensión de la estructura.




Figure 6: Cubo INE




Figure 7: Cubo IHME




Figure 8: Cubo Panamá




Figure 9: Cubo MSPAS




Figure 10: Cubo WHO Deaths




Figure 11: Cubo WHO Population

El modelado se enfocó en el modelo estrella, caracterizado por una tabla central de hechos conectada a varias tablas de dimensiones, comúnmente utilizado en sistemas de inteligencia empresarial y análisis de datos.

Justificaciones Arquitectónicas

Selección de Databricks como Plataforma Central

Se optó por la utilización de Databricks como la herramienta principal para la extracción y almacenamiento de datos, debido a su capacidad para manejar grandes volúmenes de datos y su integración con diversas fuentes de datos. A pesar de que Databricks no es una herramienta únicamente para la gestión de un Data Warehouse, sino para un Lakehouse, se decidió utilizarlo porque un Lakehouse combina las ventajas de un Data Warehouse y un Data Lake, permitiendo almacenar datos estructurados y no estructurados en un mismo lugar. Además, Databricks ofrece funcionalidades esenciales para la gestión de datos, como operaciones ACID y procesamiento de datos distribuidos, lo que lo convierte en una opción adecuada para el proyecto.

Servidor Web Local con Nginx

Para dar solución al requerimiento de compartir datos desde el entorno local, se optó por utilizar un servidor web con Nginx. Nginx es un servidor web de código abierto utilizado para servir contenido web y manejar solicitudes HTTP. Se configuró Nginx para servir los archivos de datos desde el entorno local, permitiendo que Databricks pudiera acceder a ellos a través de una URL. Esta solución es eficiente y sencilla de implementar, ya que no requiere la configuración de un servidor FTP ni servicios en la nube adicionales.

Enfoque ELT sobre ETL

Ante la situación de implementar un Data Warehouse en la nube, el proceso de consolidación corresponde a un ELT y no a un ETL, ya que se utiliza Databricks para extraer los datos y almacenarlos en su forma cruda en el Sandbox, para luego ser procesados y transformados dentro de Databricks antes de ser cargados al Data Warehouse. Este enfoque permite aprovechar las capacidades de procesamiento de Databricks y optimizar el rendimiento del sistema, evitando la necesidad de transferir grandes volúmenes de datos entre diferentes sistemas durante el proceso de transformación.

Data Warehouse Local con Greenplum

Para responder a la necesidad de tener un Data Warehouse local, se optó por utilizar Greenplum, un sistema de gestión de bases de datos relacional orientado a la analítica y el procesamiento de grandes volúmenes de datos. Greenplum ofrece funcionalidades avanzadas como particionamiento, paralelismo y optimización de consultas. Es compatible con SQL, lo que facilita la consulta y análisis de los datos. Su sistema es de tipo MPP (Massively Parallel Processing), lo que significa que puede distribuir la carga de trabajo

entre múltiples nodos, mejorando el rendimiento y la escalabilidad del sistema.

Interoperabilidad Nube-Local

La interoperabilidad entre el Data Warehouse en la nube y el Data Warehouse local se logra a través de la conexión segura establecida entre Databricks y Greenplum. Esta conexión, realizada mediante la API de Databricks, permite obtener los datos procesados y transformados en Databricks y cargarlos al Data Warehouse local, garantizando la disponibilidad y accesibilidad de los datos para su análisis y consulta desde ambos entornos. Esta solución aprovecha las ventajas de ambas infraestructuras: la escalabilidad y flexibilidad de la nube, y la seguridad y control de la infraestructura on-premise.

Herramientas de Visualización: Power BI y Apache Superset

Se optó por utilizar **Power BI**, plataforma desarrollada por Microsoft y uno de los productos líderes en visualización analítica. Power BI ofrece dos herramientas esenciales: Power Query para la preparación de datos y DAX para medidas y cálculos. Además, ofrece una amplia gama de conectores e integración con diferentes fuentes de datos, permite cargar datos en memoria primaria para mejorar el rendimiento, y soporta modelados de datos como estrella o copo de nieve de manera nativa.

Por otra parte, **Apache Superset** es una plataforma de código abierto que permite la creación de dashboards efectivos. A diferencia de Power BI, Superset no carga los datos en memoria, sino que se conecta directamente a la fuente de datos para realizar consultas y generar visualizaciones (SQL Native). Esta herramienta puede ejecutarse tanto en web como en local, y es compatible con una amplia gama de bases de datos, lo que facilitó la integración con los Data Warehouse del proyecto.

Gobernanza y Ética de Datos

Catálogo de Metadatos

Inventario de todos los conjuntos de datos del proyecto con sus atributos de origen, cobertura y clasificación.

ID	Fuente	Publicad or	Licencia	Tipo	Sensibili dad	Tabla Delta
DS-01	INE Guat emala — defuncion es	INE GT	Datos abiertos	Microdato	Alta	`sandbox. raw_ine`

DS-02	MSPAS — estadísticas vitales	MSPAS GT	Datos abiertos	Agregado	Baja	`sandbox.raw_mspas_*
DS-03	IHME GBD 2023	IHME / U. Washington	No comercial	Estimación	Baja	`sandbox.raw_ihme`
DS-04	Panamá INEC	INEC Panamá	Datos abiertos	Agregado	Baja	`sandbox.raw_panamá*`
DS-05	WHO Mortality DB	OMS	CC BY-NC-SA 3.0 IGO	Agregado	Baja	`sandbox.raw_who_mortality_*`
DS-06	PAHO Core Indicators	OPS	CC BY	Indicadores	Baja	Pendiente
DS-07	INEC Costa Rica	INEC CR	Uso público (PAD5)	Microdato	Media	Pendiente
DS-08	RENAP Guatemala	RENAP GT	Solicitud formal	Microdato	Alta (potencial)	Pendiente

Almacenamiento por Capa

Capa	Tecnología	Ubicación
Archivos GT/INE	Google Drive	`semis2_raw_data/ine/`
Archivos Panamá	OneDrive	`semi2-mortalidad/panama/`
Archivos WHO	nginx (DevTunnel)	Servidor local
Objetos S3	AWS S3	`s3://mortality-analytics-semi2/raw/`
Base relacional	RDS PostgreSQL	Schema `raw_data`, DB `mortality_dw`
Data Lake	Databricks Delta Lake	Schema `sandbox.*`

Plan de Anonimización

Marco Regulatorio

El proyecto opera en contexto académico con datos de salud pública. Para la fase de ingesta y publicación interna en Sandbox, la referencia principal es el **EU Data Act (Reglamento UE 2023/2854)** en cuanto a interoperabilidad, portabilidad y minimización del tratamiento, complementado por los principios generales de manejo ético de datos sensibles aplicables al proyecto.

Las fuentes incorporadas en los notebooks no exponen identificadores directos de las personas fallecidas (nombre, documento, contacto o equivalentes). En consecuencia, no fue necesario diseñar un proceso de anonimización primaria complejo; sí fue necesario aplicar controles de minimización, validación y agregación según la granularidad de cada fuente.

Estrategia Aplicada

La política documental del proyecto se resume en los siguientes principios:

1. **Conservar únicamente variables necesarias** para el análisis de mortalidad.
2. **Validar y normalizar** las variables sensibles o cuasi-identificadoras cuando la fuente fuese de mayor granularidad.
3. **Mantener el nivel de agregación original** cuando el proveedor ya publicara datos agregados.
4. **Reducir el riesgo de reidentificación** mediante supresión de columnas accesorias, generalización de edad y normalización de categorías atípicas.

Justificación Técnica

No fue necesario aplicar anonimización adicional sobre el material cargado porque las fuentes consultadas ya venían publicadas en formato anonimizado o agregado:

- **INE Guatemala:** microdatos sin identificadores directos; el notebook aplica supresión de columnas accesorias y generalización/validación de atributos sensibles.
- **MSPAS Guatemala:** tablas agregadas desde origen, sin nivel individual de registro.
- **IHME GBD 2023:** estimaciones agregadas por país, sexo, edad y causa.
- **Panamá INEC:** estadísticas ya agregadas por causa, sexo, edad, provincia y otras dimensiones.
- **WHO Mortality Database:** datos consolidados y agregados por país y causa.

Por tanto, el tratamiento ejecutado por el proyecto se limitó a **minimización de datos, normalización de esquemas, validación de dominios y control de calidad**, sin incorporar datos nominales ni identificadores directos en ninguna fase de Sandbox.

Clasificación de Sensibilidad

Fuente	Sensibilidad	Justificación
INE Guatemala	Media	No contiene identificadores directos; el riesgo residual proviene de cuasi-identificadores y se mitiga con supresión y generalización
MSPAS, IHME, Panamá INEC, WHO	Baja	Datos agregados en origen; no existe exposición individual
INEC Costa Rica	Media	PAD5 ya aplica supresión; riesgo residual bajo
RENAP	Alta (potencial)	Si se incorpora microdato, debe anonimizarse antes de ingesta

Técnicas Aplicadas — INE Guatemala

Supresión de columnas. Se eliminan en la ingesta:

Columna	Razón
`Puedif` (etnia)	Quasi-identificador de alto riesgo combinado con municipio pequeño
`Pnadif`, `Dnadif`, `Mnadif` (lugar de nacimiento)	Sin valor analítico para el proyecto
`Cerdef` (certificador)	Sin valor analítico
`Mredof` (municipio residencia duplicado)	Campo redundante

Generalización de edad. Edades en meses se convierten a 0 años. Valores fuera de [0, 120] se convierten a null.

Validación de causa. Solo se conservan códigos CIE-10 con formato válido. Texto libre o códigos malformados se convierten a null, evitando que funcionen como identificador indirecto.

Generalización de desconocidos. Valores "Ignorado" y vacíos se convierten a categorías genéricas ("Desconocido", "No Especificado"), reduciendo la singularidad de registros.

Riesgo residual. El vector más probable es la combinación de municipio pequeño + causa rara + grupo etario + sexo. Para Fase 2 se aplicó supresión de celdas con menos de 5 registros en las tablas de análisis. Las visualizaciones BI muestran solo agregados por departamento, no por municipio.

Decisiones de Limpieza

INE Guatemala — `sandbox.raw_ine`

Valores nulos en columnas categóricas:

Columna	Valor de relleno	Justificación
`escolaridad`	""No Especificado""	Coincide semánticamente con los valores existentes del campo
`sexo`	""Desconocido""	Campo no registrado en el acta
`estado_civil`	""Desconocido""	Campo no registrado
`nacionalidad`	""Desconocido""	Campo no registrado
`dep_ocurrencia`, `mun_ocurrencia`	""Desconocido""	Lugar de ocurrencia no disponible
`dep_residencia`, `mun_residencia`	""Desconocido""	Frecuente en extranjeros o registros rurales incompletos
`asistencia_medica`, `tipo_ocurrencia`	""Desconocido""	No registrado

Columnas que se mantienen en null:

Columna	Razón
`edad`	Númérico — `null` es la representación correcta de edad desconocida; imputar sesgaría distribuciones
`causa_cie10`	`null` significa código ausente o inválido — semántica propia para análisis de causas

Cumplimiento EU Data Act

Principios EU Data Act Aplicados

El **Reglamento UE 2023/2854 (EU Data Act)** establece normas armonizadas sobre el acceso y uso justo de datos en la Unión Europea. Si bien el proyecto opera en Guatemala, la cláusula de cooperación internacional del encargo PNUD exige el cumplimiento de este marco regulatorio. A continuación se detalla cómo cada principio fue implementado en la plataforma:

Principio EU Data Act	Implementación en la Plataforma
Portabilidad de datos	Delta Lake con esquemas versionados, exportable en formatos abiertos (Parquet/CSV). Los datos pueden ser transferidos entre sistemas sin pérdida de fidelidad.
Interoperabilidad	Uso de estándares internacionales: CIE-10 para codificación de causas de muerte, ISO 3166 para códigos de país, grupos etarios estandarizados según OMS.
Minimización de datos	Solo se ingieren las columnas necesarias para el análisis de mortalidad. Se suprimen campos accesorios durante la ingesta para reducir la superficie de datos.
Transparencia	Documentación completa del linaje de datos (data lineage) desde la fuente hasta el dashboard. Diccionario de datos, catálogo de metadatos y registro de decisiones de limpieza disponibles en MkDocs.
Protección de datos sensibles	Los datos presentados en visualizaciones son exclusivamente agregados (departamental/causal/grupo etario). No se expone ningún registro individual ni información personal identificable en ningún dashboard o informe.
Acceso justo	Los datos procesados pueden ser consultados desde ambos Data Warehouse (nube y local), garantizando que múltiples partes interesadas puedan acceder a la información sin dependencia de un único proveedor.

Compromisos por Fuente

Fuente	Restricción	Compromiso Adquirido
--------	-------------	----------------------

IHME GBD 2023	Licencia no comercial	Uso exclusivamente académico; no se comercializan los datos ni los modelos derivados
WHO Mortality DB	CC BY-NC-SA 3.0 IGO	Atribución obligatoria en todas las publicaciones y dashboards que utilicen estos datos
RENAP	Solicitud bajo Ley 57-2008	Si se recibe microdato individual, anonimizar completamente antes de cualquier ingesta
INEC Costa Rica	PAD5 uso público	No redistribuir archivos brutos; solo publicar agregados o resultados analíticos

Cumplimiento Ético en Visualizaciones

- Los datos presentados en Power BI y Apache Superset son **agregados** a nivel departamental, causal y grupo etario.
- No se expone ningún registro individual ni información personal identificable en ningún dashboard.
- Las tasas de mortalidad se calculan sobre denominadores poblacionales publicados por la OMS (WHO Population Database).
- Se aplica supresión de celdas con menos de 5 registros para evitar riesgos de reidentificación en tablas de análisis.

Insights y Análisis Pre/Post-COVID

Análisis Comparativo de Mortalidad en Centroamérica (2015-2023)

El análisis comparativo de la evolución histórica de defunciones por causa en Centroamérica (2015-2023) revela que el shock de mortalidad asociado a la pandemia se concentró mayoritariamente en la categoría de infecciones respiratorias y tuberculosis (CG0390), y no en la categoría específica de COVID-19 (CG0995), cuyo volumen registrado fue consistentemente menor en los seis países analizados. Este desacople entre ambas categorías sugiere un patrón de subregistro o clasificación imprecisa de la causa de muerte durante el período crítico 2020-2021, fenómeno que se observa con mayor intensidad en Guatemala y Honduras —donde las defunciones por infecciones respiratorias

alcanzaron picos de aproximadamente 38,000 y 25,000 casos respectivamente— en contraste con Costa Rica y Panamá, donde el incremento fue marginal y casi imperceptible frente a la tendencia histórica.

Por otro lado, causas crónicas estructurales como los trastornos neurológicos (CG0590) y las enfermedades cardiovasculares (CG0530) mantuvieron una tendencia secular ascendente sin alteraciones visibles durante la pandemia, evidenciando que la crisis sanitaria fue un choque agudo y transitorio superpuesto a una carga de enfermedad crónica preexistente que continuó su curso independiente del contexto pandémico.

La caída abrupta de ambas categorías pandémicas hacia 2022-2023 debe interpretarse con cautela, ya que podría reflejar tanto una recuperación epidemiológica real como un rezago en la consolidación de datos de los años más recientes, una limitación común en fuentes de estadísticas vitales.




Figure 12: Gráfica 1: Tendencias de causas en Centroamérica




Figure 13: Gráfica 2: Detalle por causa

Carga de Mortalidad por País

El análisis del total acumulado de defunciones por país (todas las causas, todo el período disponible) confirma a Guatemala como el país con la mayor carga absoluta de mortalidad en Centroamérica, con 779,300 defunciones registradas, una cifra que representa aproximadamente el 34% del total regional y casi duplica el volumen del segundo país en la lista, Honduras (446,200).




Figure 14: Gráfica 3: Total de defunciones acumuladas por país

Comparación Pre-COVID vs Post-COVID

La comparación de mortalidad pre-COVID (2015-2019) y post-COVID (2020-2023) en Guatemala muestra un incremento de 361,395 a 417,953 defunciones, equivalente a 56,558 muertes adicionales y una variación relativa de +15.65%, la mayor diferencia absoluta registrada entre los seis países centroamericanos analizados.

Al contrastar este resultado con el resto de la región, se observa que:

- **Honduras** presenta el incremento porcentual más alto (+23.29%)
- **Nicaragua** le sigue con +17.96%
- **El Salvador** constituye el único caso atípico de la región, con una variación negativa de -2.29%
- **Costa Rica y Panamá** se ubican en un rango de crecimiento similar, entre 11% y 14%

Esto indica que, si bien Guatemala concentra el mayor volumen absoluto de muertes adicionales, no es el país donde la mortalidad creció proporcionalmente más durante el período post-COVID.




Figure 15: Gráfica 4: Comparativa pre vs post COVID por país

Perfiles de Mortalidad: Guatemala vs Panamá

La comparación entre los principales perfiles de mortalidad de Guatemala y Panamá revela que las enfermedades cardiovasculares constituyen la primera causa de muerte en ambos países, lo que indica un patrón compartido en la principal causa de mortalidad de la región.

Sin embargo, el resto del perfil de causas diverge de forma notable:

- En Guatemala, **Diabetes y enfermedades renales** ocupa el segundo lugar con aproximadamente 120,000 defunciones acumuladas, una cifra ocho veces mayor que la registrada para la misma causa en Panamá (~15,000).
- **COVID-19** figura como la octava causa principal en Guatemala (~27,000 defunciones), mientras que no aparece como categoría individual dentro del top 10 de Panamá.
- **Lesiones autoinfligidas y violencia interpersonal** aparece como séptima causa en Guatemala (~37,000 defunciones) sin una categoría equivalente visible en el top 10 panameño.

Esta diferencia sugiere que ambos países emplean esquemas de clasificación de causa de muerte con distinto nivel de granularidad, lo cual debe documentarse como una limitación de comparabilidad entre fuentes heterogéneas.




Figure 16: Gráfica 5: Perfil de mortalidad Guatemala




Figure 17: Gráfica 6: Perfil de mortalidad Panamá

Tendencia Histórica y Persistencia del Exceso de Mortalidad

La tendencia histórica de defunciones anuales en Guatemala muestra un comportamiento estable entre 2015 y 2019 (de aproximadamente 81,000 a 86,000 muertes anuales), seguido de un incremento marcado a partir de 2020 que alcanza su punto máximo en 2021 con cerca de 120,000 defunciones, el valor más alto de toda la serie histórica disponible.

Tras este pico, la mortalidad en Guatemala desciende a aproximadamente 96,000 en 2022, pero **se mantiene de forma sostenida por encima de los niveles pre-pandemia** durante 2022, 2023 y 2024 (en torno a 96,000-100,000), sin retornar a la tendencia previa a 2020.

Al comparar este comportamiento con Panamá, se observa que ambos países comparten la misma forma de curva —estabilidad, pico en 2021 y descenso posterior—; sin embargo, **Panamá muestra un patrón de recuperación más cercano a sus niveles pre-pandemia**

hacia 2023 (~23,000, frente a ~21,000 en 2019), mientras que Guatemala no logra volver a su nivel histórico previo en ningún punto de la serie posterior a 2021.

Esta diferencia en la trayectoria de recuperación post-pico constituye un hallazgo relevante, en la medida en que sugiere una **persistencia más prolongada del exceso de mortalidad en Guatemala** respecto a Panamá.




Figure 18: Gráfica 7: Tendencia anual Guatemala vs Panamá

Dashboards Analíticos en Apache Superset

Tres dashboards fueron diseñados para responder preguntas estratégicas del encargo PNUD/MSPAS, cubriendo las dimensiones de **tiempo** (pre vs post COVID), **causa** (CIE-10/GBD), **geografía** (departamentos de Guatemala) y **demografía** (sexo, grupo etario).

Dashboard 1: Pre vs Post COVID — Guatemala

Objetivo: Comparar la mortalidad general entre el período pre-COVID (2015-2019) y post-COVID (2020-2024), validando con datos oficiales del MSPAS.

#	Visualización	Tipo	Fuente	Qué responde
1.1	Total Defunciones Pre-COVID (2015-2019)	Big Number + Trend	`v_ine_complet a`	¿Cuál fue la carga base de mortalidad antes de la pandemia?

1.2	Total Defunciones Post-COVID (2020-2024)	Big Number + Trend	`v_ine_completa`	¿Cómo cambió la mortalidad total después de 2020?
1.3	Variación Pre vs Post COVID	Big Number	`v_ine_completa`	¿Cuál es el cambio porcentual neto entre períodos?
1.4	Defunciones Mensuales 2015-2024	Línea (Time Series)	`v_ine_completa`	¿Hay patrones estacionales? ¿Se observa el pico COVID-2020/2021?
1.5	Defunciones por Año — Pre vs Post	Barras Agrupadas	`v_ine_completa`	¿Qué años fueron los más letales? ¿Hay tendencia al alza/baja?
1.6	Tasa de Mortalidad Nacional (MSPAS)	Línea (Time Series)	`v_mspas_nacional`	¿Coinciden los datos del INE con la tasa oficial del MSPAS?




Figure 19: Total Defunciones Pre-COVID




Figure 20: Total Defunciones Post-COVID



Figure 21: Variación Pre vs Post COVID




Figure 22: Defunciones Mensuales 2015-2024




Figure 23: Defunciones por Año — Pre vs Post COVID




Figure 24: Tasa de Mortalidad Nacional MSPAS

Hallazgos del Dashboard 1:

- Exceso de mortalidad 2020-2021:** Se observa un pico pronunciado en 2020 y 2021, reflejando el impacto directo de COVID-19 y el colapso del sistema de salud.
- Efecto persistente 2022-2024:** La mortalidad post-pico se mantiene elevada respecto al baseline pre-COVID, indicando efectos indirectos (enfermedades crónicas desatendidas, salud mental, interrupción de servicios).
- Validación MSPAS:** Los datos del INE (registro individual de defunciones) se alinean con las tasas oficiales del MSPAS para años pre-COVID. Divergencias post-2020 pueden indicar subregistro.

4. **Estacionalidad:** Se observa mayor mortalidad en meses de invierno (noviembre-febrero) por enfermedades respiratorias, patrón que se acentuó durante la pandemia.

Dashboard 2: Causas de Muerte

Objetivo: Desglosar la mortalidad por causa GBD Nivel 2, identificando qué enfermedades cambiaron más su participación relativa entre períodos, y contextualizar Guatemala en Centroamérica.

#	Visualización	Tipo	Fuente	Qué responde
2.1	Defunciones por Causa GBD L2	Treemap	`v_ine_complet a`	¿Cuáles son las causas dominantes en Guatemala?
2.2	Top 10 Causas de Muerte	Treemap	`v_ine_complet a`	¿Qué ranking tienen las enfermedades?
2.3	Tendencia Pre vs Post COVID	Línea	`v_ine_complet a`	¿Cómo cambia la mortalidad total por período a través del tiempo?
2.4	Tendencia de Causas en Centroamérica (IHME)	Líneas Múltiples	`v_ihme_centro america`	¿Es Guatemala un caso atípico frente a la región?




Figure 25: Defunciones por Causa GBD L2




Figure 26: Top 10 Causas de Muerte




Figure 27: Tendencia Pre vs Post COVID




Figure 28: Tendencia de Causas en Centroamérica IHME

Hallazgos del Dashboard 2:

1. **COVID-19 como nueva causa principal:** A partir de 2020, COVID-19 aparece como causa GBD, desplazando potencialmente a enfermedades cardiovasculares o neoplasias del primer lugar.
2. **Efecto sustitución:** Enfermedades crónicas (diabetes, hipertensión) muestran un aumento indirecto por desatención durante la pandemia.
3. **Causas externas:** Homicidios y accidentes muestran patrones diferentes — algunos estudios sugieren reducción durante confinamientos, con rebote posterior.
4. **Contexto regional IHME:** Guatemala presenta un perfil de mortalidad distinto al resto de Centroamérica (mayor carga de enfermedades transmisibles, menor carga de neoplasias por pirámide poblacional más joven).

Dashboard 3: Geografía y Demografía

Objetivo: Identificar disparidades geográficas en la mortalidad a nivel departamental, y patrones demográficos por sexo y grupo etario.

#	Visualización	Tipo	Fuente	Qué responde
3.1	Defunciones por Departamento	Treemap		¿Qué departamentos concentran mayor mortalidad absoluta?
3.2	Defunciones por Grupo Etario y Año	Barras apiladas		¿Qué grupos de edad fueron más afectados y cuándo?
3.3	Defunciones por Sexo y Año	Barras Apiladas		¿Hay diferencias anuales de mortalidad entre hombres y mujeres?
3.4	Resumen: Departamento × Causa	Tabla Dinámica		¿Qué causa predomina en cada departamento?




Figure 29: Defunciones por Departamento




Figure 30: Defunciones por Grupo Etario y Año




Figure 31: Defunciones por Sexo y Año




Figure 32: Resumen Departamento por Causa

Hallazgos del Dashboard 3:

- 1. **Concentración urbana:** El departamento de Guatemala (área metropolitana) concentra la mayor cantidad absoluta de defunciones por densidad poblacional.
- 2. **Desigualdad en salud:** Departamentos del corredor seco (Chiquimula, Jutiapa, El Progreso) o con alta población indígena (Quiché, Totonicapán) muestran tasas elevadas de mortalidad por enfermedades prevenibles.

3. **Impacto etario de COVID-19:** El grupo de 60+ años fue el más afectado en 2020-2021, pero también se revela un aumento en grupos de 40-59 años (población económicamente activa).
4. **Sobremortalidad masculina:** Consistentemente, los hombres muestran mayor mortalidad anual que las mujeres; la brecha se amplió durante la pandemia.
5. **Perfil departamental diferenciado:** La tabla dinámica permite identificar que ciertas causas (desnutrición, enfermedades infecciosas) predominan en departamentos específicos, lo cual es crítico para focalizar intervenciones de política pública.

Notas Metodológicas

Período de Análisis

- **Pre-COVID:** 2015–2019 (5 años de referencia)
- **Post-COVID:** 2020–2024 (incluye años pandémicos y post-pandémicos)
- La dimensión `dimtiempo.espre_covid` segmenta automáticamente los datos.

Normalización de Causas

Las causas de muerte se normalizaron a **GBD Nivel 2** (16 categorías) mediante un crosswalk desde códigos CIE-10.

Limitaciones Conocidas

1. **Subregistro:** El INE depende del registro civil; defunciones no registradas (especialmente en áreas rurales) no aparecen en los datos.
2. **Causas mal definidas:** Un porcentaje de defunciones tiene causa "R99" (CIE-10) o similar, limitando el análisis causal.
3. **Datos MSPAS post-2019:** La tasa por 100k habitantes de MSPAS solo está disponible hasta 2019; para 2020+ solo se tiene el conteo absoluto de defunciones.
4. **WHO limitado a 2022:** Los datos de población WHO solo cubren hasta 2022, limitando el cálculo de tasas para 2023-2024.
5. **Panamá no incluido en dashboards:** Por simplicidad, los dashboards priorizan Guatemala. La vista `vihmecentroamerica` provee contexto regional con datos IHME.

Cumplimiento Ético (EU Data Act)

- Los datos presentados son **agregados** a nivel departamental/causal/grupo etario.
- No se expone ningún registro individual ni información personal identificable.
- Las tasas se calculan sobre denominadores poblacionales publicados por WHO.

Recomendaciones de Política

Con base en la evidencia recopilada y analizada durante el proyecto, se presentan las siguientes recomendaciones de política pública para el Ministerio de Salud Pública y Asistencia Social (MSPAS) y la institución cliente:

1. Fortalecimiento del Sistema de Registro de Estadísticas Vitales

Hallazgo que la sustenta: El desacople entre las categorías de infecciones respiratorias y COVID-19 durante 2020-2021, junto con la presencia de causas mal definidas (R99), evidencia debilidades en la codificación y registro de causas de muerte.

Recomendación: Implementar un programa de capacitación continua para el personal de registro civil y codificadores médicos en la aplicación correcta de la clasificación CIE-10, con énfasis en la certificación de causas de muerte en contextos de emergencia sanitaria. Establecer un sistema de auditoría de calidad de codificación con retroalimentación periódica.

Indicador de éxito: Reducción del porcentaje de causas mal definidas (Capítulo XVIII CIE-10) a menos del 5% del total de defunciones anuales en un plazo de 3 años.

2. Programa Nacional de Prevención de Enfermedades Crónicas No Transmisibles

Hallazgo que la sustenta: Las enfermedades cardiovasculares y la diabetes/enfermedades renales constituyen las dos principales causas de muerte en Guatemala, con una carga de diabetes ocho veces mayor que la observada en Panamá.

Recomendación: Diseñar e implementar un programa nacional de detección temprana y manejo de diabetes e hipertensión arterial en el primer nivel de atención, priorizando los departamentos con mayor carga de mortalidad por estas causas. Incluir componentes de educación nutricional, promoción de actividad física y acceso a medicamentos esenciales.

Indicador de éxito: Reducción de la tasa de mortalidad por diabetes y enfermedades renales en al menos un 10% en 5 años, medido a través de las estadísticas vitales del INE.

3. Intervenciones Focalizadas por Departamento

Hallazgo que la sustenta: Los dashboards de geografía y demografía revelan disparidades significativas entre departamentos, con mayor carga de enfermedades prevenibles en departamentos del corredor seco y áreas con alta población indígena.

Recomendación: Adoptar un enfoque de asignación de recursos basado en evidencia, priorizando los departamentos que muestran las mayores tasas de mortalidad por causas prevenibles. Implementar unidades móviles de salud en los departamentos con menor acceso a servicios de salud. Fortalecer la red de Atención Primaria en Salud (APS) en los

departamentos identificados como prioritarios: Quiché, Totonicapán, Chiquimula, Jutiapa y El Progreso.

Indicador de éxito: Convergencia de las tasas de mortalidad departamentales hacia la media nacional en un horizonte de 5 a 10 años.

4. Sistema de Monitoreo Continuo de Exceso de Mortalidad

Hallazgo que la sustenta: La persistencia del exceso de mortalidad en Guatemala hasta 2024 —sin retornar a los niveles pre-pandemia— a diferencia de Panamá donde se observa una recuperación más cercana a su línea base, sugiere efectos indirectos prolongados de la pandemia.

Recomendación: Establecer un sistema de vigilancia de exceso de mortalidad como indicador centinela permanente, utilizando la metodología y plataforma desarrollada en este proyecto. Este sistema debe generar alertas tempranas ante desviaciones significativas de la mortalidad esperada, permitiendo una respuesta rápida del MSPAS ante emergencias sanitarias o deterioros en la salud poblacional.

Indicador de éxito: Implementación de un tablero de control de exceso de mortalidad actualizado mensualmente, con acceso a tomadores de decisión del MSPAS y publicación de reportes trimestrales.

5. Estandarización Regional de Registros de Mortalidad

Hallazgo que la sustenta: Las diferencias en los esquemas de clasificación de causas entre Guatemala y Panamá limitan la comparabilidad regional y la capacidad de realizar análisis transfronterizos robustos.

Recomendación: Promover, a través del Consejo de Ministros de Salud de Centroamérica y República Dominicana (COMISCA), una iniciativa de armonización de los sistemas de registro de estadísticas vitales, adoptando estándares comunes de codificación CIE-10, definiciones de causas de muerte y protocolos de certificación. Esta estandarización es crítica para el monitoreo regional de los Objetivos de Desarrollo Sostenible (ODS) relacionados con salud.

Indicador de éxito: Adopción de un protocolo regional de certificación de defunciones y codificación CIE-10 por al menos cuatro países de la región en un plazo de 3 años.

6. Inversión en Infraestructura de Datos para Salud Pública

Hallazgo que la sustenta: La fragmentación de fuentes de datos identificada durante el proyecto (INE, MSPAS, RENAP, fuentes internacionales funcionando como silos independientes) obstaculiza la capacidad de generar evidencia oportuna para la toma de decisiones.

Recomendación: Institucionalizar la plataforma analítica desarrollada como prueba de concepto, transformándola en un sistema de información de salud interoperable que integre los registros administrativos del MSPAS, las estadísticas vitales del INE y las fuentes internacionales de referencia. Asignar presupuesto específico para la sostenibilidad de la infraestructura de datos (nube, personal técnico, licencias) como parte del presupuesto ordinario del MSPAS.

Indicador de éxito: Operacionalización de la plataforma con actualización trimestral de datos y acceso a dashboards analíticos para todas las direcciones del MSPAS en un plazo de 2 años.

Documento preparado por la firma consultora para el Programa de las Naciones Unidas para el Desarrollo (PNUD) y el Ministerio de Salud Pública y Asistencia Social (MSPAS) de Guatemala, en el marco del proyecto "Plataforma Analítica de Mortalidad End-to-End". Junio 2026.